Внутренний словарь русскоязычной языковой модели: детокенизация, словоизменение и словообразование

Ангелина Липина, Анастасия Мальцева, Кира Чугаева
НИУ ВШЭ, ОП «Фундаментальная и компьютерная лингвистика»

Аннотация

Работа Kaplan et al. (2025) показала, что языковая модель Llama 2 восстанавливает многотокенное английское слово в скрытом состоянии его последнего токена. Мы воспроизводим ключевые эксперименты этой работы на русском языке с моделью Saiga (Llama 3 8B, дообученная на русском) и добавляем эксперимент о словоизменении и словообразовании. Скрытые состояния последнего токена отличают русские слова от псевдослов с точностью до 85,6% (k-NN). В отличие от английского, у русских слов предпоследний токен почти так же информативен, как последний; контроль на английских словах в той же модели показывает, что это различие связано с языком. Низкие значения строгих метрик восстановления слова в значительной мере объясняются тем, что на средних слоях лучший токен оказывается английским. Формы одного существительного группируются вместе начиная со второго слоя (99,4% на пятом слое), включая супплетивные пары без общих токенов. Сравнение с синонимами указывает, что сходство, определяемое именно словом, преобладает на слоях 2–5, а на средних слоях — сходство по значению.

1. Введение

Языковые модели получают на вход токены — фрагменты слов, полученные алгоритмами вроде BPE (Sennrich et al., 2016). Редкие и длинные слова разбиваются на несколько токенов, особенно в неанглийских языках (Petrov et al., 2023). Kaplan et al. (2025) показали, что Llama 2 тем не менее формирует в скрытом состоянии последнего токена представление целого слова (детокенизация), и назвали это внутренним словарём модели. Их эксперименты проведены на английском языке, в котором практически отсутствует флективное словоизменение.

Русский язык позволяет проверить эти выводы в условиях богатой морфологии и задать новый вопрос: что формирует модель — представление конкретной словоформы («журналами») или лексемы («журнал» во всех формах)? Мы воспроизводим эксперименты разделов 3 и 4 статьи на русском материале, проводим контроль на английских словах в той же модели и исследуем словоизменение, словообразование и роль значения.

2. Обзор литературы

Детокенизация. Kaplan et al. (2025) различают слова и псевдослова по скрытым состояниям (k-NN, 89% на слое 13 против 61% для предпоследнего токена), восстанавливают слово через *Logit Lens* и *Patchscopes* и связывают процесс с вниманием на первых слоях и с выходами FFN. Feucht et al. (2024) описывают «стирание» информации о предыдущих токенах в последнем токене многотокенного слова. Интерпретация FFN как памяти «ключ–значение» предложена Geva et al. (2021).

Методы чтения скрытых состояний. *Logit Lens* (nostalgebraist, 2020) проецирует промежуточное состояние на словарь, Belrose et al. (2023) предложили обучаемый вариант. *Patchscopes* (Ghandeharioun et al., 2024) подставляет скрытое состояние в другой запрос и декодирует его генерацией.

Латентный язык. Wendler et al. (2024) показали, что Llama 2 при обработке неанглийского текста проходит через промежуточное представление, близкое к английскому.

Морфология во внутренних представлениях. Li and Subramani (2026) исследуют лексическую идентичность и словоизменительные признаки в 25 моделях и шести языках,

включая русский: лексема лучше всего декодируется на ранних слоях, словоизменительные признаки — на всех. Словообразование в этой работе не рассматривается.

Расширение словаря. Mundra et al. (2024) сравнивают способы инициализации новых токенов (в том числе для русского) с последующим дообучением; Kaplan et al. (2025) предлагают расширение без изменения параметров модели.

3. Методы и гипотезы

Мы проверяем пять гипотез. **H1**: скрытые состояния последнего токена русской модели отличают слова от псевдослов, как в Kaplan et al. (2025). **H2**: из-за флективной морфологии разница между последним и предпоследним токеном для русского меньше, чем для английского. **H3**: низкие строгие метрики восстановления слова частично объясняются промежуточным представлением, близким к английскому (Wendler et al., 2024), и форматом генерации. **H4**: модель группирует формы одного слова (лексему), а не слова с одинаковой грамматической формой. **H5**: сходство форм одного слова на части слоёв не сводится к сходству значения.

Зонды. Для H1–H2 используются k-NN (k = 4) с евклидовым (как в статье) и косинусным расстоянием и линейный классификатор (стандартизация, PCA до 256 компонент, логистическая регрессия). Для H3 — обратный *logit lens* argmax_w ⟨E_w, h⟩ по матрице входных эмбеддингов E и *Patchscopes* с промптом «Далее одно и то же слово дважды: 1) X 2)» (перевод промпта из кода статьи). Для H4–H5 — центрированное косинусное сходство: из скрытых состояний каждого слоя вычитается среднее по набору слов.

4. Данные, модель и эксперименты

Модель. IlyaGusev/saiga_llama3_8b (Gusev, 2024): Llama 3 8B (Grattafiori et al., 2024), дообученная на русских инструкциях; 32 слоя, размерность 4096, словарь 128 256 токенов; загрузка в 4-битном формате NF4 (Dettmers et al., 2023) на GPU T4 (Google Colab). Скрытые состояния снимаются со всех 33 уровней (0 — эмбеддинги). Слово подаётся как BOS и « слово».

Слова. 100 000 частотных слов из wordfreq (Speer, 2022), только русские буквы. С помощью pymorphy3 (Korobov, 2015) оставлены слова, известные словарю, без имён, фамилий, отчеств, топонимов, организаций и сокращений: 83 920 слов.

Эксперимент 1 (H1–H2). Выбрано 1200 слов из 2–4 токенов (372/550/278 по длине). Псевдослова строятся из токенов, стоящих на тех же позициях в словах той же длины, как в статье. Дополнительно мы отбрасываем кандидатов, совпадающих со словом из списка или словаря, и кандидатов с неканонической токенизацией (encode(decode(t)) ≠ t); без этого фильтра таких псевдослов было 18,3%. Пять наборов псевдослов (слои 42–46), разбиение 80/20 со стратификацией по метке и длине, 95%-е доверительные интервалы по начальным значениям генератора, шумовой уровень по 50 перестановкам меток. Последний и предпоследний токены сравниваются на словах из 3–4 токенов.

Эксперимент 2 (контроль к H2). Тот же конвейер на английских словах из wordfreq с тем же распределением длин; два начальных значения генератора, евклидов k-NN.

Эксперимент 3 (H3). (а) 1000 однотокенных слов искусственно разрезаются на 2–5 частей; (б) в 745 однотокенных слов вносится одна опечатка (опечатки, дающие настоящее слово, исключены); для (а) и (б) применяется *logit lens* к состоянию последнего куска. (в) Для 400 многотокенных слов состояние последнего токена с каждого слоя 1–32 подставляется в промпт *Patchscopes*; генерируется L+3 токена. Строгие метрики статьи: лучший токен совпадает со словом; ответ начинается со слова. Дополнительно: ранг слова среди всех токенов (top-10,

top-100), алфавит лучшего токена и «мягкая» проверка *Patchscopes*, удаляющая из начала ответа нумерацию вида «2)».

Эксперимент 4 (H4). 250 существительных, формы в шести падежах и двух числах (pymorphy3); исключены неоднозначные и редкие формы (Zipf < 2), итого 1789 форм. Пары: формы одного слова с общим первым токеном (А1) и без общих токенов (А2); контроли — разные слова с общим первым токеном (Б) и без общих токенов (В); разные слова в одной грамматической форме (Г). Задача ближайшего соседа: для каждой формы сравниваются равные по размеру группы — другие формы того же слова и другие слова в той же падежно-числовой форме (уровень случайности 50%). Дополнительно: 70 вручную отобранных словообразовательных пар пяти типов (типы соответствуют DerivBase.Ru, Vodolazsky, 2020) и 23 супплетивные пары без общих токенов.

Эксперимент 5 (H5). 15 пар синонимов и 20 пар слов одной смысловой группы, каждая в начальной форме и в одной и той же форме (творительный падеж, мн. число), сравниваются с формами одного слова.

5. Результаты

Таблица 1. Эксперименты 1–2: пиковая точность k-NN (евклидово расстояние). «3–4 т.» — слова из 3–4 токенов. Δ — разница последнего и предпоследнего токена.

	Последний, все	Последний, 3–4 т.	Предпосл., 3–4 т.	Δ на пике	Δ, слои 16–32
Русский (5 тестов)	0,856 (сл. 10)	0,873 (сл. 10)	0,855 (сл. 13)	+1,8 п. п.	−9,4 п. п.
Английский (2 теста)	0,956 (сл. 11)	0,991 (сл. 15)	0,887 (сл. 12)	+10,4 п. п.	+24,9 п. п.Ы
Kaplan et al. (Llama 2, англ.)	0,89 (сл. 13)	—	0,61	—	—

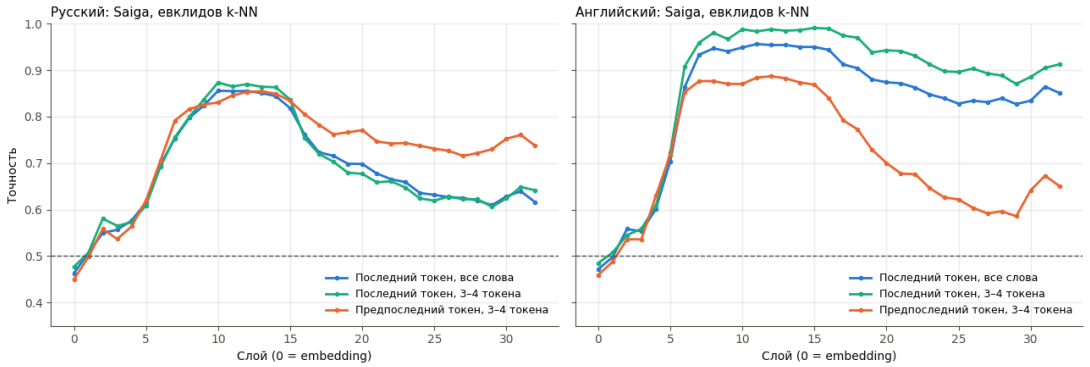


Рис. 1. Эксперименты 1–2. Точность евклидова k-NN по слоям для русских (слева) и английских (справа) слов в одной модели. Синяя линия — последний токен, все слова; зелёная и оранжевая — последний и предпоследний токены для слов из 3–4 токенов.

H1 подтверждается. Точность евклидова k-NN выходит на плато 0,84–0,86 на слоях 10–15 (табл. 1); на слое 0 она равна 0,46. Нижняя граница доверительного интервала выше 95-го перцентиля шума (не более 0,565) начиная со слоя 3. Косинусный k-NN достигает 0,875 (слой 11), линейный классификатор — 0,931 (слой 7) и сохраняет 0,90 на последнем слое. Канонические и нефильтрованные псевдослова дают близкие кривые (разница от −2,1 до +3,5 п. п.).

H2 подтверждается. Для русских слов последний токен лишь на 1,8 п. п. лучше предпоследнего, а на слоях 16–32 предпоследний лучше на 9,4 п. п. (значимо на каждом слое, парный t-тест по разным случайным начальным значениям, $p < 0,05$ без поправки). Для

английских слов в той же модели картина соответствует статье: +10,4 п. п. на пике и +24,9 п. п. на поздних слоях (рис. 1).

Таблица 2. Эксперимент 3: доля восстановленных слов на лучшем слое (в скобках) и хотя бы на одном слое.

Опыт и метрика	Пик	Хотя бы на одном слое	Kaplan et al. (Llama 2)
Разрезанные слова, top-1	11,5% (6)	26,2%	>80% / 93,2%
Разрезанные слова, top-100	65,0% (5)	81,7%	—
Опечатки, top-1	3,0% (7)	6,7%	≈40% / 66%
Опечатки, top-100	30,6% (5)	51,4%	—
Patchscopes, строго	10,5% (7)	17,2%	64% / 77,4%
Patchscopes, нестрого	24,2% (7)	38,8%	—



Рис. 2. Эксперимент 3. Слева: доля слов, для которых исходное слово входит в первые 1/10/100 токенов по *logit lens*. В центре: алфавит лучшего токена (разрезанные слова). Справа: *Patchscopes* со строгой и нестрогой проверкой.

H3 подтверждается частично. По строгим метрикам результаты значительно ниже, чем у Kaplan et al. (2025) (табл. 2). Доля латинских токенов среди лучших по *logit lens* равна 0 на слое 0, 0,28 на слое 4, 0,76 на слое 8 и 0,95 на последнем слое (рис. 2); например, состояние для «д|ир|ектор» на слоях 4–8 ближе всего к токену Director. При этом исходное слово входит в первые 100 токенов для 65% разрезанных слов (слой 5). Мягкая проверка *Patchscopes* увеличивает долю восстановленных слов с 10,5% до 24,2%; пик (слой 7) совпадает с диапазоном статьи (слои 5–7), но абсолютные значения остаются ниже.

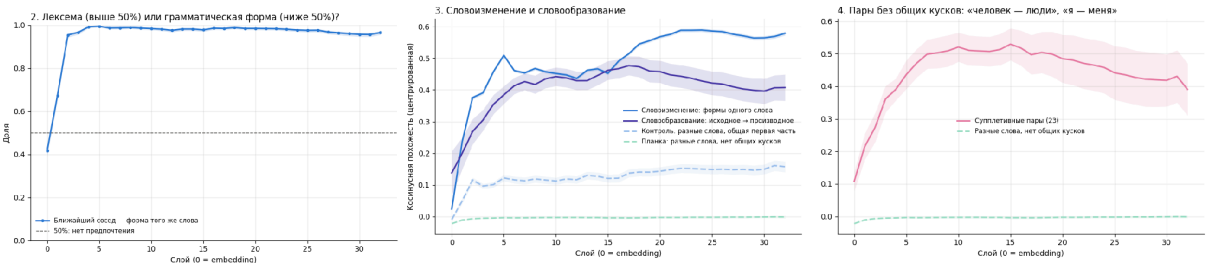


Рис. 3. Эксперимент 4. Слева: доля форм, у которых ближайший сосед — форма того же слова (50% — нет предпочтения). В центре: сходство форм одного слова и словообразовательных пар с контролями. Справа: супплетивные пары. Полосы — 95%-е доверительные интервалы.

H4 подтверждается. На слое 0 ближайший сосед формы чаще оказывается другим словом в той же форме (41,6% «то же слово»). Доля «то же слово» составляет 95,4% на слое 2, 99,4% на слое 5 и не опускается ниже 95% до последнего слоя (рис. 3). Разности А1−Б и А2−В положительны и значимы на слоях 1–32 (на слое 5: 0,423 и 0,367). Супплетивные пары на слое 5 имеют сходство 0,436 против −0,004 у случайных пар без общих токенов. Словообразовательные пары на слое 5 сходны слабее форм одного слова (0,384 против 0,509),

но сильнее контроля с общим первым токеном (0,122). На слоях 6–16 кривые словоизменения и словообразования близки, после слоя 16 расходятся (около 0,59 и 0,40).

H5 подтверждается для слоёв 2–5. Формы одного слова значимо ближе, чем синонимы и слова одной смысловой группы, на слоях 2–5, в том числе при общем окончании (рис. 4 в приложении В). На слоях 10–12 и 15 слова одной смысловой группы значимо ближе, чем формы одного слова. На слоях 17–32 формы одного слова снова ближе синонимов в начальной форме. Слова одной смысловой группы в одной форме ближе случайных слов в той же форме на слоях 1–32.

6. Выводы

Основной вывод Kaplan et al. (2025) воспроизводится на русском языке: скрытое состояние последнего токена содержит информацию о слове на ранних и средних слоях. Для русского эта информация доступна уже на предпоследнем токене, и это различие связано с языком, а не с моделью. Строгие метрики восстановления слова занижают результат для русского, так как на средних слоях лучший токен — английский. Модель группирует формы одного существительного в лексему начиная со второго слоя, включая супплетивные формы. Сходство, определяемое словом, преобладает на слоях 2–5, на средних слоях — сходство по значению, на поздних снова возрастает роль конкретной формы; это согласуется с трёхфазной картиной Wendler et al. (2024) и с выводом Li and Subramani (2026) о раннем формировании лексемы.

7. Ограничения и обсуждение

Использована одна модель (Saiga, 4 бита); Llama 2 не запускалась, поэтому сравнение с числами статьи качественное. Saiga — чат-модель; вместе с русским промптом и коротким ответом (L+3 токена) это может занижать результаты *Patchscopes*. Списки синонимов (15), слов одной группы (20), словообразовательных (70) и супплетивных (23) пар невелики, поэтому границы слоёв в экспериментах 4–5 приблизительны; значимость по слоям приводится без поправки на множественные сравнения. Эксперименты статьи с FFN, вниманием и расширением словаря не повторялись. Возможные продолжения: базовая модель и английский промпт в *Patchscopes*, расширение словообразовательного материала, другие языки с богатой морфологией.

Список литературы

Belrose N. et al. Eliciting Latent Predictions from Transformers with the Tuned Lens. arXiv:2303.08112, 2023.

Dettmers T., Pagnoni A., Holtzman A., Zettlemoyer L. QLoRA: Efficient Finetuning of Quantized LLMs. NeurIPS, 2023.

Feucht S., Atkinson D., Wallace B. C., Bau D. Token Erasure as a Footprint of Implicit Vocabulary Items in LLMs. EMNLP, 2024.

Geva M., Schuster R., Berant J., Levy O. Transformer Feed-Forward Layers Are Key-Value Memories. EMNLP, 2021.

Ghandeharioun A., Caciularu A., Pearce A., Dixon L., Geva M. Patchscopes: A Unifying Framework for Inspecting Hidden Representations of Language Models. ICML, 2024.

Grattafiori A. et al. The Llama 3 Herd of Models. arXiv:2407.21783, 2024.

Gusev I. saiga_llama3_8b. https://huggingface.co/IlyaGusev/saiga_llama3_8b, 2024.

Kaplan G., Oren M., Reif Y., Schwartz R. From Tokens to Words: On the Inner Lexicon of LLMs. ICLR, 2025.

Korobov M. Morphological Analyzer and Generator for Russian and Ukrainian Languages. AIST, 2015.

Li M., Subramani N. Model Internal Sleuthing: Finding Lexical Identity and Inflectional Features in Modern Language Models. ACL, 2026.

Mundra N., Kishore A. N., Dabre R., Puduppully R., Kunchukuttan A., Khapra M. M. An Empirical Comparison of Vocabulary Expansion and Initialization Approaches for Language Models. CoNLL, 2024.

nostalgebraist. Interpreting GPT: the logit lens. LessWrong, 2020.

Petrov A., La Malfa E., Torr P., Bibi A. Language Model Tokenizers Introduce Unfairness Between Languages. NeurIPS, 2023.

Sennrich R., Haddow B., Birch A. Neural Machine Translation of Rare Words with Subword Units. ACL, 2016.

Speer R. wordfreq (v3). Zenodo, 2022.

Vodolazsky D. DerivBase.Ru: a Derivational Morphology Resource for Russian. LREC, 2020.

Wendler C., Veselovsky V., Monea G., West R. Do Llamas Work in English? On the Latent Language of Multilingual Transformers. ACL, 2024.

Приложение А. Декларация об использовании ИИ

При подготовке работы использовался ассистент Claude (Anthropic). С его помощью:

- обсуждались план экспериментов и модификации методики (каноническая токенизация псевдослов, словарная фильтрация, несколько случайных начальных значений и перестановочный тест, проверка для английского, ранговые метрики и нестрогая проверка Patchscopes, смысловой контроль); идея эксперимента о словоизменении и словообразовании была предложена преподавателем курса;
- написан и отлажен код ноутбуков Google Colab на основе кода репозитория Kaplan et al. (2025);
- интерпретировались результаты и выполнялся поиск литературы;
- подготовлены черновики текста препринта и схематических иллюстраций.

Все эксперименты запускались авторами; все числа и графики в препринте получены из вывода этих запусков. Текст и интерпретации проверены авторами.

Приложение Б. Воспроизводимость

Код: три ноутбука Google Colab, каждый выполняется целиком:

- 01_word_vs_nonword.ipynb — эксперименты 1–2;
- 02_word_retrieval.ipynb — эксперимент 3;
- 03_morphology_lexeme_vs_form.ipynb — эксперименты 4–5.

Репозиторий: https://github.com/AngelinaLip/interpretation_project_tokens2words . Основные параметры: random seeds = 42–46; k = 4; разбиение 80/20; 50 перестановок; 1000 разрезанных слов, 1000 кандидатов для опечаток (745 после фильтрации), 400 слов для Patchscopes; 250 существительных, не менее 5 форм на слово, не более 5000 пар на тип.

Приложение B. Дополнительные материалы

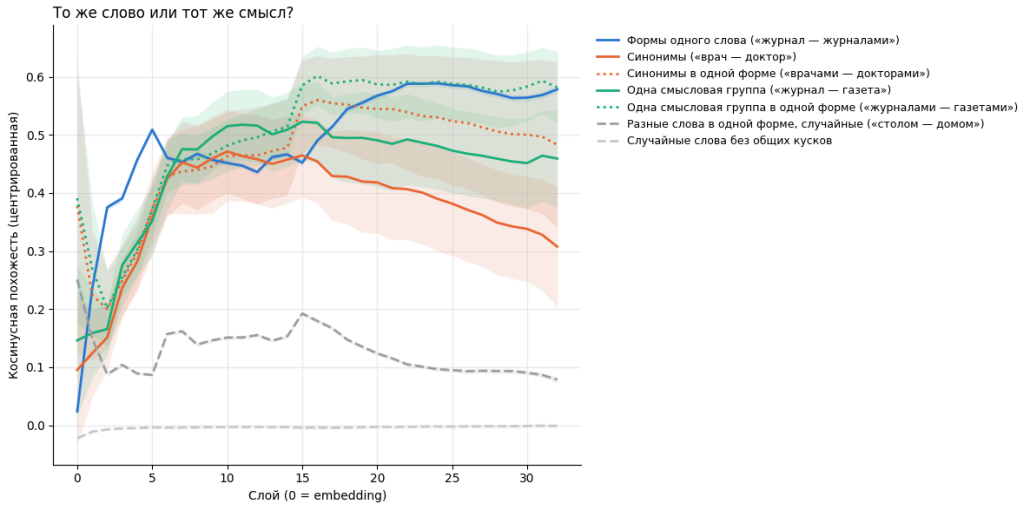


Рис. 4. Эксперимент 5. Центрированное косинусное сходство форм одного слова, синонимов и слов одной смысловой группы (сплошные линии — начальная форма, пунктир — одна и та же форма) и контрольных пар.

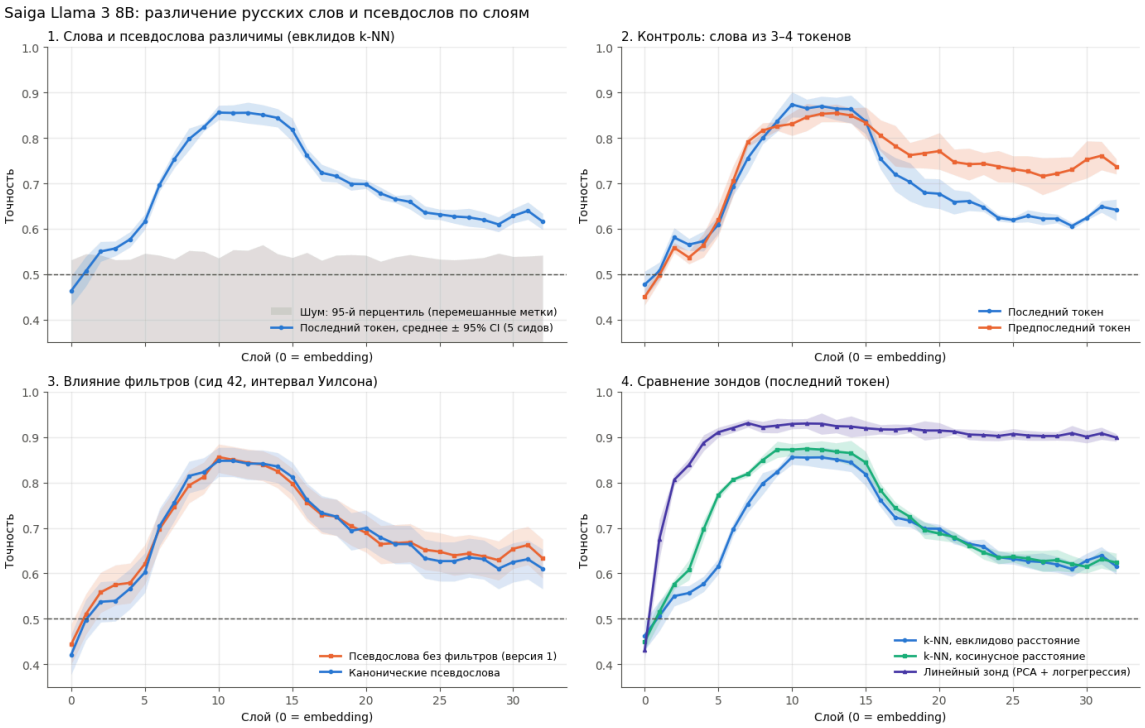


Рис. 5. Эксперимент 1. (1) Евклидов k-NN, последний токен, среднее по пяти зёрнам с 95%-м интервалом; серым — 95-й перцентиль шума. (2) Последний и предпоследний токены, слова из 3–4 токенов. (3) Нефильтрованные и канонические псевдослова. (4) Три зонда.

Таблица 3. Эксперимент 3: лучший токен по *logit lens* для состояния последнего куска разрезанного слова.

Слово	Вход	Слой 0	Слой 4	Слой 8	Слой 12	Слой 16	Слой 32
директор	д|ир|ектор	ектор	Director	Director	_Manager	Director	stylesheet
симптом	симпт|о|м	м	symptoms	symptoms	symptoms	gnome	campaign
когда	к|огд|а	а	when	when	WHEN	when	rearr
орган	о|р|г|ан	ан	organs	organs	Organ	Organ	bachelor

Таблица 4. Эксперимент 4: пять ближайших соседей формы среди 1789 форм набора.

Форма	Слой 0	Слой 5	Слой 32
журналах	городах, президентах, компаниях, уровнях, …	журналов, газетах, журналами, изданиях, журнале	журналам, армиях, президентах, литературах, папах
человек	люди, женщина, людям, ребенок, лет	люди, женщина, людям, ребенок, муж	ребенок, мальчик, люди, мужик, мужчина